LOS AGENTES DE LA IA

1º Ingeniería de Robótica Software
Evolución y futuro de la robótica

David Valiño Iglesias
Jorge Martínez Díaz
Diego Robles González

Índice

Introducción. 1

Marco teórico. 2

Resumen de la documentación. 2

Desarrollo: análisis comparado de ideas principales. 4

1. La desinformación y la apariencia de verdad como uno de los mayores peligros de la IA generativa. 4

2. Los sesgos y la discriminación pueden reproducirse mediante la IA. 6

3. El desarrollo de la IA exige responsabilidad, regulación y evaluación crítica. 8

Conclusión. 11

Bibliografía: 12

Introducción.

La inteligencia artificial (IA) se ha consolidado como una de las tecnologías más influyentes del siglo XXI, aportando un cambio radical a múltiples ámbitos de la sociedad, desde la educación y la industria, hasta la comunicación y la toma de decisiones. Dentro de este contexto, los agentes de inteligencia artificial, como ChatGPT, Microsoft Copilot o Google Gemini, representan una evolución muy destacable en la interacción entre humanos y sistemas computacionales. Estos agentes no sólo procesan información, van mucho más allá, son capaces de generar contenido, asistir en tareas complejas y adaptarse a distintos contextos de uso.

El presente trabajo se centra en analizar la evolución de estos agentes de IA a lo largo de las últimas décadas, prestando especial atención a los avances tecnológicos que han permitido su desarrollo actual. También, se abordará una reflexión crítica sobre su futuro, explorando tanto el posible "techo" que estas tecnologías podrían llegar a alcanzar como los posibles riesgos y amenazas asociados a lo que esto podría suponer. Este tema resulta especialmente relevante debido al impacto creciente que estas herramientas están teniendo en la sociedad, aumentando su popularidad exponencialmente.

Para la elaboración de este estudio, se han seleccionado diversos artículos académicos y fuentes especializadas que permiten construir una visión rigurosa y fundamentada. Estos textos aportan un análisis crítico sobre los riesgos y desafíos derivados del desarrollo de la inteligencia artificial, además de ofrecer una perspectiva histórica mediante líneas temporales que facilitan la comprensión de su evolución. También, las contribuciones de expertos recogidas en dichas fuentes permiten equilibrar el análisis, destacando no solo las amenazas (negativo), sino también las ventajas y oportunidades que ofrece la IA (positivo), evitando así una visión sesgada o excesivamente alarmista.

El marco teórico de este trabajo se basa en el análisis de tres estudios principales sobre inteligencia artificial. En Abeliuk y Gutiérrez (2021) se explica su evolución histórica y fundamentos, en Franganillo (2022) se analizan las aplicaciones actuales de la IA generativa y sus riesgos, y en Weidinger et al. (2022) se clasifican los principales problemas asociados a los modelos de lenguaje. A partir de estas fuentes, se realiza un análisis comparado centrado en tres ideas clave del artículo principal (Weidinger et al., 2022): la desinformación, los sesgos y la necesidad de un desarrollo responsable.

Marco teórico.

Resumen de la documentación.

-En Abeliuk y Gutiérrez (2021) se presenta una explicación general sobre la historia y evolución de la inteligencia artificial. El documento comienza destacando a Ada Lovelace como una de las primeras personas en imaginar que las máquinas podían hacer algo más que cálculos matemáticos. Después, se señala como momento clave la conferencia de Dartmouth en 1956, donde nace oficialmente el concepto de inteligencia artificial.

Los autores explican también los primeros avances importantes, como el programa Logic Theorist, que fue capaz de resolver problemas usando reglas simples. A partir de aquí, el texto distingue dos enfoques principales: la inteligencia artificial simbólica, basada en reglas y lógica, y la inteligencia artificial conexionista, basada en redes neuronales que aprenden a partir de datos.

Además, el artículo analiza cómo en los últimos años la inteligencia artificial ha avanzado mucho gracias al aumento de la capacidad de los ordenadores y a la gran cantidad de datos disponibles. Ejemplos como ImageNet o AlphaGo muestran que las máquinas pueden superar a los humanos en ciertas tareas.

Por otro lado, también se explican algunas limitaciones importantes, como el alto coste computacional, la necesidad de muchos datos y la dificultad para entender cómo funcionan algunos modelos. También se mencionan problemas éticos, como los sesgos o el impacto en la sociedad.

En general, el documento ofrece una visión clara y equilibrada de la inteligencia artificial, explicando tanto sus avances como sus riesgos, lo que ayuda a entender mejor su desarrollo y su importancia actual.

-En Franganillo (2022) se analiza el desarrollo reciente de la inteligencia artificial aplicada a la generación de contenido, así como sus principales oportunidades y riesgos. El autor explica que en los últimos años ha habido un crecimiento muy rápido en tecnologías capaces de crear textos, imágenes, vídeos y audios de forma automática.

El documento describe cómo funcionan estas herramientas, destacando el uso de redes neuronales y modelos de lenguaje, que son capaces de generar textos muy similares a los que escribimos los humanos. También se mencionan aplicaciones en ámbitos como el marketing, el periodismo o la creación de contenido digital, donde estas tecnologías permiten ahorrar tiempo y mejorar la productividad.

Además, el autor analiza otras aplicaciones importantes como los vídeos deepfake, que permiten crear imágenes o vídeos falsos muy realistas, o la clonación de voz, que puede imitar la voz de una persona con gran precisión. También se estudia la generación de imágenes a partir de texto mediante herramientas como DALL·E, que han supuesto un gran avance en creatividad digital.

Sin embargo, el artículo pone mucho énfasis en los riesgos. Entre ellos destacan la desinformación, la creación de noticias falsas, el uso malicioso de deepfakes y los problemas relacionados con la propiedad intelectual. También se menciona el impacto que estas tecnologías pueden tener en profesiones creativas, como escritores, periodistas o diseñadores.

Por último, el autor plantea la necesidad de desarrollar un uso ético de la inteligencia artificial, así como normas y regulaciones que eviten abusos. En general, el documento ofrece una visión crítica y equilibrada, mostrando que la IA es una herramienta muy potente, pero que debe utilizarse de forma responsable para evitar consecuencias negativas.

-En Weidinger et al. (2022) se analiza de forma detallada los riesgos asociados a los modelos de lenguaje, como los utilizados en sistemas de inteligencia artificial actuales. El objetivo principal del documento es clasificar y explicar los distintos tipos de riesgos que pueden surgir del uso de estas tecnologías.

El artículo propone una organización de estos riesgos en seis grandes categorías. Entre ellas se encuentran los problemas de discriminación y sesgos, la desinformación, los usos maliciosos, los riesgos en la interacción entre humanos y máquinas, así como los impactos sociales, económicos y medioambientales. Esta clasificación permite entender mejor cómo afectan estos sistemas a distintos ámbitos de la sociedad.

Además, los autores explican que algunos de estos riesgos ya se han observado en sistemas actuales, mientras que otros son posibles problemas futuros que podrían aparecer a medida que

la tecnología siga avanzando. Esto permite tener una visión más completa, no solo del presente, sino también de lo que puede ocurrir en los próximos años.

El documento también analiza ejemplos concretos, como la generación de información falsa, la reproducción de estereotipos o la posibilidad de utilizar estos sistemas para crear fraudes o manipular a las personas. Asimismo, se destacan problemas como la pérdida de privacidad o el impacto en el empleo.

Por último, el artículo plantea la importancia de desarrollar estas tecnologías de forma responsable, proponiendo medidas para reducir los riesgos, como mejorar los datos de entrenamiento, regular su uso o diseñar sistemas más seguros. En general, se trata de un estudio muy completo que ayuda a comprender tanto los peligros actuales como los retos futuros de la inteligencia artificial.

Desarrollo: análisis comparado de ideas principales.

1. La desinformación y la apariencia de verdad como uno de los mayores peligros de la IA generativa.

Una de las ideas más importantes del artículo de Weidinger et al. (2022) es que debemos tener en cuenta que los modelos de lenguaje pueden generar información falsa, engañosa o de baja calidad incluso cuando no existe una intención maliciosa por parte del usuario. Esto ocurre porque estos sistemas no funcionan comprobando si una afirmación es verdadera o falsa, sino calculando qué palabras o frases son más probables dentro de un contexto determinado, dando lugar a equivocaciones. Por tanto, una respuesta generada por inteligencia artificial puede estar muy bien redactada, parecer coherente y transmitir seguridad, pero aun así contener errores o afirmaciones falsas.

Los autores resumen esta idea cuando afirman que “whether or not a sentence is likely does not reliably indicate whether the sentence is also correct” (Weidinger et al., 2022, p. 218). Esta cita indica que el hecho de que una frase sea probable desde el punto de vista estadístico no significa que sea verdadera. La IA puede producir una respuesta convincente porque ha aprendido patrones lingüísticos, pero eso no implica que comprenda realmente el contenido ni que pueda verificarlo como lo haría una persona consultando fuentes fiables.

Este riesgo es especialmente importante porque afecta directamente a la confianza de los usuarios en la información. Cuando una respuesta aparece formulada con claridad, orden y seguridad, muchas personas tienden a asumir que es correcta. El problema es que esta

apariencia de verdad puede resultar peligrosa en ámbitos sensibles como la medicina, el derecho, la educación o la política. Por ejemplo, una recomendación médica incorrecta, una explicación legal falsa o una interpretación errónea de un hecho histórico pueden provocar consecuencias reales muy serias. Weidinger et al. señalan que la información falsa en áreas como la salud o la ley puede causar daños materiales, ya que una persona podría tomar decisiones importantes basándose en una respuesta equivocada (Weidinger et al., 2022, p. 219).

Esta idea se relaciona directamente con el artículo de Franganillo (2022), quien analiza la desinformación desde el punto de vista del contenido generado por inteligencia artificial. Su enfoque amplía el problema más allá del texto, ya que estudia también imágenes, vídeos deepfake y clonación de voz. Esto permite comprender que la desinformación actual no se limita a noticias falsas escritas, sino que también puede presentarse en forma de vídeos manipulados, voces artificiales o imágenes sintéticas, las posibilidades son interminables. En este sentido, Franganillo explica que los deepfakes son vídeos manipulados mediante IA con un aspecto tan realista que pueden hacer difícil detectar que han sido falseados (Franganillo, 2022, p. 3).

Por su parte, Abeliuk y Gutiérrez (2021) ayudan a entender el origen técnico de este problema. Aunque su artículo no se centra específicamente en la desinformación, sí explica cómo la inteligencia artificial ha avanzado gracias al aprendizaje profundo, al aumento de la capacidad computacional y a la disponibilidad masiva de datos. Según estos autores, en la década de 2010 el desarrollo de hardware especializado y la existencia de grandes cantidades de datos abiertos impulsaron el crecimiento de las redes neuronales y de sus aplicaciones en visión, lenguaje y reconocimiento de patrones. Esta aportación es importante porque explica por qué los contenidos generados por IA son cada vez más realistas. No se trata de que la máquina “piense” como una persona, sino de que ha sido entrenada con enormes cantidades de datos y puede producir resultados muy sofisticados. Abeliuk y Gutiérrez también señalan que una ventaja de las redes neuronales es que no necesitan que se les indiquen todas las reglas de forma explícita, ya que aprenden a partir de los datos de entrenamiento. Esta característica explica parte de su potencia, pero también parte de sus riesgos: si los datos contienen errores, sesgos o información falsa, el sistema puede reproducirlos (Abeliuk y Gutiérrez, 2021, pp. 17-18).

En conclusión, la desinformación es uno de los riesgos más importantes de la IA generativa porque combina tres factores: la capacidad técnica para producir contenido convincente, la dificultad presente en los humanos para distinguir lo real de lo artificial y la posibilidad de

utilizar estas herramientas para manipular o engañar. Weidinger et al. explican el problema desde el funcionamiento de los modelos de lenguaje; Franganillo muestra sus manifestaciones concretas en textos, imágenes y deepfakes; y Abeliuk y Gutiérrez aportan el contexto histórico y técnico que permite entender cómo se ha llegado a este nivel de sofisticación. Por ello, el problema no está solo en que la IA pueda equivocarse, sino en que sus errores pueden presentarse con una apariencia de verdad muy difícil de detectar.

2. Los sesgos y la discriminación pueden reproducirse mediante la IA.

Otra idea clave del artículo de Weidinger et al. (2022) es que los modelos de lenguaje pueden reproducir sesgos sociales presentes en los datos con los que han sido entrenados. Esto significa que la inteligencia artificial no es neutral por defecto. Aunque muchas veces se perciba como una tecnología objetiva porque funciona mediante algoritmos, realmente, aprende a partir de textos, imágenes y datos creados por personas. Por tanto, si esos datos contienen prejuicios, estereotipos o desigualdades históricas, el modelo puede reproducirlos en sus respuestas.

Weidinger et al. sitúan este problema dentro de una de sus seis grandes áreas de riesgo: "Discrimination, Hate speech and Exclusion" (Weidinger et al., 2022, p. 215). Esta categoría incluye riesgos como la reproducción de estereotipos sociales, la generación de lenguaje ofensivo, la exclusión de ciertos grupos y el peor rendimiento de los modelos para algunas lenguas o comunidades. Esta clasificación es importante porque muestra que el sesgo no es un error aislado, sino un problema amplio que puede afectar a distintas formas de interacción entre las personas y la IA.

El origen de este problema está en el modo en que estos modelos aprenden. Los modelos de lenguaje se entrenan con grandes cantidades de datos, muchos de ellos procedentes de libros digitalizados, páginas web y otros textos disponibles en internet. Si en esos contenidos aparecen prejuicios sociales, lenguaje discriminatorio o asociaciones injustas entre grupos humanos y determinadas características, el sistema puede aprender estos patrones y terminar por imitarlos al encontrarse presentes en sus datos de entrenamiento (Weidinger et al., 2022, p. 216). Por eso, el problema no está solo en la tecnología, sino también en la sociedad de la que proceden los datos.

Esta idea se relaciona directamente con Abeliuk y Gutiérrez (2021), quienes explican que una de las características principales de las redes neuronales actuales es que no necesitan que se les indiquen reglas explícitas, sino que aprenden a partir de los datos. La IA puede descubrir

patrones complejos sin que una persona tenga que programarlos uno por uno, pero también puede absorber patrones problemáticos si los datos no son los adecuados. Abeliuk y Gutiérrez también advierten que los datos deben estar cuidadosamente seleccionados para evitar resultados injustos. Esta idea complementa muy bien el planteamiento de Weidinger et al., porque ambos documentos coinciden en que la calidad de los datos es decisiva. Un modelo entrenado con datos poco representativos puede funcionar peor para ciertos grupos, reforzar estereotipos o generar respuestas sesgadas. Por tanto, el sesgo no debe entenderse como un fallo menor, sino como una consecuencia posible del propio proceso de entrenamiento (Abeliuk y Gutiérrez, 2021, p. 18).

Además, Weidinger et al. explican que estos sesgos pueden producir daños de dos tipos. Por un lado, pueden causar daños representacionales, cuando un grupo aparece descrito de forma injusta, inferior o estereotipada. Por otro lado, pueden causar daños materiales, cuando el funcionamiento del sistema afecta al acceso a oportunidades, servicios o recursos (Weidinger et al., 2022, p. 216). Por ejemplo, si una IA usada en selección de personal asocia determinados trabajos con hombres y otros con mujeres, puede reforzar desigualdades laborales. Del mismo modo, si un sistema funciona peor con ciertos dialectos, lenguas o formas de expresión, puede excluir a comunidades enteras.

Franganillo (2022) también aporta una visión importante sobre este problema, especialmente al analizar la generación de imágenes mediante IA. El autor explica que algunos sistemas capaces de crear imágenes a partir de texto han sido criticados porque sus resultados reproducen una visión marcada por los datos con los que han sido entrenados. En concreto, señala que DALL·E mini recibió críticas porque sus imágenes podían representar una visión occidental y perpetuar sesgos raciales y de género (Franganillo, 2022, p. 8). Esta aportación es muy útil porque muestra que el sesgo no aparece únicamente en textos, sino también en imágenes generadas artificialmente.

Esto es especialmente grave porque las imágenes tienen un fuerte poder persuasivo. Si una IA genera imágenes en las que determinadas profesiones aparecen asociadas casi siempre a hombres, o si representa ciertos grupos sociales de forma estereotipada, no solo está produciendo una imagen incorrecta, sino reforzando ideas ya presentes en la sociedad. Además, al tratarse de contenido generado automáticamente, puede parecer neutral o técnico, cuando en realidad está reproduciendo patrones aprendidos de datos humanos.

Franganillo también advierte que la IA generativa puede afectar al ámbito creativo y comunicativo, precisamente porque sus resultados se difunden con facilidad y pueden llegar a muchas personas. Esta idea se conecta con el problema de los sesgos porque un contenido sesgado generado por IA no se queda necesariamente en un uso privado, sino que puede publicarse en redes sociales, medios digitales, campañas publicitarias o materiales educativos. Por tanto, el sesgo puede amplificarse si estos sistemas se utilizan de forma masiva sin revisión humana.

En conjunto, los tres documentos permiten entender que la IA puede reproducir desigualdades de varias formas. Weidinger et al. ofrecen una clasificación amplia y sistemática de los riesgos de discriminación; Abeliuk y Gutiérrez explican la causa técnica relacionada con los datos de entrenamiento; y Franganillo muestra cómo estos sesgos pueden aparecer en aplicaciones concretas de IA generativa, especialmente en imágenes y contenidos digitales. La comparación entre los tres textos demuestra que la inteligencia artificial no debe considerarse neutral, sino una tecnología que necesita supervisión, evaluación crítica y criterios éticos claros.

En conclusión, los sesgos y la discriminación son uno de los grandes riesgos de la inteligencia artificial porque pueden aparecer de forma silenciosa. Un sistema puede parecer avanzado, útil y objetivo, pero al mismo tiempo reproducir prejuicios presentes en sus datos. Por eso, no basta con mejorar la capacidad técnica de los modelos; también es necesario revisar qué datos se utilizan, quién queda representado, quién queda excluido y qué consecuencias pueden tener sus respuestas. La IA puede ser una herramienta muy potente, pero si no se controla adecuadamente, también puede reforzar desigualdades ya existentes.

3. El desarrollo de la IA exige responsabilidad, regulación y evaluación crítica.

La tercera idea principal es que el desarrollo de la inteligencia artificial debe ir acompañado de responsabilidad ética, regulación y evaluación crítica. Weidinger et al. (2022) insisten en que no basta con crear modelos cada vez más potentes, rápidos o capaces, sino que también es necesario anticipar sus riesgos, evaluarlos y aplicar medidas para reducir posibles daños. Esta perspectiva es importante porque muchos problemas de la IA no aparecen únicamente cuando la tecnología ya está implantada, sino que pueden surgir desde las fases iniciales de diseño, entrenamiento y despliegue.

Los autores explican que la innovación responsable implica que quienes desarrollan una tecnología deben “anticipate, reflect upon, and evaluate the benefits and risks” (Weidinger et

al., 2022, p. 215). Esta cita resume una idea clave: innovar no significa solo avanzar técnicamente, sino también pensar en las consecuencias sociales de ese avance. Una tecnología puede ser muy eficaz desde el punto de vista técnico y, al mismo tiempo, generar daños si se utiliza sin control, sin transparencia o sin criterios éticos claros.

En el caso de los modelos de lenguaje, esta responsabilidad es todavía más importante porque su paso de la investigación al uso cotidiano puede ser muy rápido. Herramientas como asistentes conversacionales, generadores de texto o sistemas de apoyo a decisiones pueden llegar a millones de personas en poco tiempo. Por eso, Weidinger et al. defienden que las organizaciones que desarrollan estos modelos tienen una responsabilidad especial, ya que son las primeras que conocen sus capacidades, sus limitaciones y sus posibles riesgos. Si estas organizaciones no evalúan los daños antes de lanzar sus sistemas, la sociedad puede acabar enfrentándose a problemas que podrían haberse previsto.

Esta idea se relaciona claramente con Franganillo (2022), quien también defiende la necesidad de un uso responsable de la IA generativa. Su artículo muestra que estas tecnologías ofrecen oportunidades importantes en la creación de contenido, pero también pueden convertirse en una amenaza si se usan de forma incorrecta. En concreto, Franganillo explica que los avances en IA permiten generar textos, imágenes, vídeos y voces artificiales con gran realismo, lo que abre posibilidades en ámbitos como el entretenimiento, la publicidad, la accesibilidad o la producción audiovisual. Sin embargo, esos mismos avances pueden utilizarse para crear engaños, manipular la opinión pública o dañar la reputación de una persona.

Franganillo resume este doble carácter de la tecnología al afirmar que estos desarrollos “ofrecen grandes oportunidades potenciales, pero a la vez quedan expuestos a ciertos usos cuestionables” (Franganillo, 2022, p. 1). Esta cita complementa muy bien la idea de Weidinger et al., porque ambos textos coinciden en que el problema no es solo la existencia de la IA, sino el modo en que se desarrolla y se utiliza. La inteligencia artificial puede servir para mejorar procesos, ahorrar tiempo y ampliar capacidades humanas, pero también puede facilitar nuevas formas de fraude, desinformación o abuso si no existen límites claros.

La diferencia entre ambos documentos está en el enfoque. Franganillo se centra más en ejemplos visibles y actuales, como los deepfakes, la clonación de voz, las imágenes sintéticas o los textos generados automáticamente. Su aportación es útil porque permite ver de manera concreta cómo la IA puede afectar a la sociedad. Weidinger et al., en cambio, proponen una

estructura más amplia para clasificar y evaluar riesgos. Por eso, ambos documentos se complementan: uno aporta casos concretos y el otro ofrece una herramienta conceptual para ordenar esos riesgos y pensar cómo mitigarlos.

Abeliuk y Gutiérrez (2021) también aportan elementos importantes para esta reflexión. En la parte final de su artículo, plantean que la IA trae consigo dilemas éticos porque se trata de una tecnología con gran capacidad para transformar la realidad social. Estos autores no se limitan a describir avances técnicos, sino que también formulan preguntas sobre su impacto en la economía, la sociedad, los seres humanos, el medio ambiente, la seguridad y la posible aparición de sistemas más avanzados. Por ejemplo, se preguntan cómo se distribuirá la riqueza creada por las máquinas, quién decidirá los usos de la IA y cómo se controlarán los sesgos introducidos en estos sistemas (Abeliuk y Gutiérrez, 2021, p. 20).

Esta aportación es especialmente útil porque demuestra que los dilemas éticos no son un añadido secundario, sino una parte central del debate sobre inteligencia artificial. La IA no afecta solo a programadores, ingenieros o empresas tecnológicas, sino a toda la sociedad. Puede influir en el empleo, en la educación, en la información que recibimos, en la seguridad, en la privacidad y en la manera en que se toman decisiones importantes. Por eso, su desarrollo no puede dejarse únicamente en manos de quienes la producen o de quienes buscan rentabilizarla económicamente.

En este sentido, la regulación aparece como una necesidad lógica. Regular no significa frenar todo avance tecnológico, sino establecer criterios para que ese avance no dañe derechos fundamentales ni aumente desigualdades. Una regulación adecuada debería exigir transparencia sobre el uso de sistemas de IA, mecanismos de revisión humana en ámbitos sensibles, protección de datos personales y responsabilidad clara cuando se produzcan daños. Si una IA genera una recomendación errónea en un ámbito médico, jurídico o educativo, no basta con decir que “lo hizo el algoritmo”; debe haber responsables humanos y organizaciones que respondan por el diseño y el uso de esa herramienta.

Además, la evaluación crítica debe mantenerse durante todo el ciclo de vida de la tecnología. No es suficiente comprobar un modelo una sola vez antes de lanzarlo, porque los usos sociales de la IA cambian con el tiempo. Una herramienta creada para ayudar a redactar textos puede acabar utilizándose para generar noticias falsas; una tecnología de clonación de voz pensada para accesibilidad puede usarse para cometer estafas; y un generador de imágenes puede servir

tanto para fines artísticos como para crear contenido engañoso. Por eso, los riesgos deben revisarse de forma continua.

En mi opinión, una de las conclusiones más fuertes que se extrae de los tres documentos es que la IA no es buena ni mala por sí misma, pero tampoco es neutral. Sus efectos dependen de cómo se diseña, con qué datos se entrena, quién la controla, para qué se utiliza y qué límites se establecen. Weidinger et al. aportan la idea de innovación responsable; Franganillo muestra los riesgos concretos de la IA generativa; y Abeliuk y Gutiérrez amplían el debate hacia cuestiones éticas, económicas y sociales. En conjunto, los tres textos permiten defender que el futuro de la IA no dependerá solo de la tecnología, sino también de las decisiones sociales, políticas y económicas que se tomen alrededor de ella.

Conclusión.

A lo largo de este trabajo se ha revisado la evolución de los agentes de inteligencia artificial y sus principales capacidades, riesgos y desafíos. Uno de los hallazgos más importantes es que los sistemas actuales, especialmente los modelos de lenguaje han alcanzado un desarrollo que les permite generar contenido muy convincente. Esto aumenta tanto sus beneficios como sus peligros. En particular, se ha observado que la desinformación es uno de los riesgos más significativos. Estos sistemas pueden producir respuestas plausibles pero incorrectas porque funcionan mediante probabilidades lingüísticas, no verificaciones objetivas (Weidinger et al., 2022, p. 218). Este aspecto conecta directamente con el objetivo inicial del trabajo, que buscaba analizar no solo el avance tecnológico, sino también sus implicaciones. Otro resultado clave es que la inteligencia artificial no es neutral; puede reproducir sesgos presentes en los datos de entrenamiento. Como se ha señalado, los modelos aprenden patrones de grandes volúmenes de información. Esto implica que pueden heredar errores existentes si están presentes en los datos (Abeliuk y Gutiérrez, 2021, pp. 18-20). Esta cuestión es especialmente relevante porque afecta la equidad y la justicia en el uso de estas tecnologías. Refuerza la necesidad de supervisión humana y diseño responsable. En esta misma línea, se ha probado que los contenidos generados por IA, incluyendo textos, imágenes o videos, pueden tener un fuerte impacto social. Su realismo puede convertir estas herramientas en un "arma de doble filo" si se utilizan sin control ético o social (Franganillo, 2022, p. 7). Respecto a los objetivos planteados al inicio, el trabajo ha demostrado que la evolución de la IA no se puede entender solo desde una perspectiva técnica. Como señalan los autores mencionados, el desarrollo de estos sistemas debe ir acompañado de responsabilidad, evaluación crítica y regulación. La innovación tecnológica,

por sí sola, no garantiza un impacto positivo. Sus efectos dependen en gran medida del uso que se haga de ella y de los marcos éticos y legales que la rodeen (Weidinger et al., 2022, p. 215). Por tanto, el objetivo de reflexionar críticamente sobre el futuro de estos agentes se cumple al evidenciar que su crecimiento plantea oportunidades y riesgos estructurales. Las implicaciones de este estudio son amplias. En primer lugar, se aparece la necesidad de desarrollar sistemas más transparentes y comprensibles, capaces de reducir errores y facilitar la interpretación de sus resultados. En segundo lugar, se refuerza la importancia de establecer marcos regulativos que limiten los usos dañinos de la IA, especialmente en áreas sensibles como la información, la educación o la toma de decisiones automatizadas. Además, se destaca la necesidad de una alfabetización digital adecuada que permita a los usuarios entender las limitaciones de estas herramientas y no asumir sus respuestas como verdades absolutas. Finalmente, como líneas futuras de investigación, sería importante profundizar en métodos para reducir la desinformación generada por IA, mejorar la detección de contenido sintético como los deepfakes y desarrollar técnicas más eficaces para suavizar tendencias y desviaciones en los modelos. También es importante investigar el impacto a largo plazo de estos sistemas en el empleo, la creatividad y la estructura social. En definitiva, la inteligencia artificial seguirá evolucionando, pero su impacto dependerá en gran medida de cómo se gestione su desarrollo. Esto convierte este campo en un área clave de estudio interdisciplinario en los próximos años.

Bibliografía:

-Abeliuk, A., & Gutiérrez, C. (2021). Historia y evoluación de la inteligencia artificial. Revista Bits de Ciencia, (21), 14-21.

-Franganillo, J. (2022). Contenido generado por inteligencia artificial: oportunidades y amenazas. Anuario ThinkEPI, 16.

-Weidinger, L., Uesato, J., Rauh, M., Griffin, C., Huang, P. S., Mellor, J., ... & Gabriel, I. (2022, June). Taxonomy of risks posed by language models. In *Proceedings of the 2022 ACM conference on fairness, accountability, and transparency* (pp. 214-229).